Dùng GAN để phát sinh mẫu thử DDoS

1. Trần Đức Anh MHV: 250101005
2. Huỳnh Ngọc Hưng MHV: 250101027
3. Trần Thanh Dũng MHV: 250201053

Giảng viên hướng dẫn: **PGS.TS. Nguyễn Tấn Cầm**

Ngày 2 tháng 4 năm 2026

Nội dung báo cáo

1. 1. Giới thiệu
2. 2. Phương pháp đề xuất
3. 3. Hướng A
4. 4. Hướng B
5. 5. Thực nghiệm
6. 6. Kết luận

Bối cảnh & Động lực

Vấn đề

- DDoS attacks ngày càng tinh vi
- IDS dựa ML cần **dữ liệu huấn luyện đa dạng**
- Dữ liệu DDoS thực: khó thu thập, mất cân bằng

Câu hỏi nghiên cứu

Liệu GAN có thể sinh ra fake DDoS traffic **đủ thực** để:

A. Test & cải thiện IDS?

B. Bypass detector hiện tại?

Đóng góp chính

1. **Hướng A**: Pure WGAN sinh mẫu DDoS realistic
2. **Hướng B**: Arms race GAN $\Leftrightarrow$ Detector (2 rounds)
3. Đề xuất **Validity Score** – metric mới đánh giá tính realistic
4. SHAP explainability phân tích feature importance

Dataset: CIC-DDoS2019

Tổng quan

Nguồn	Canadian Institute for Cybersecurity
# Features	80 (sau preprocessing)
Train set	68,380 samples
Test set	14,653 samples/class

Phân loại features (novel)

- **16 Functional:** Protocol, Flag counts, Header Length, Flow Duration
  → *Định nghĩa bản chất DDoS*
- **64 Non-functional:** Packet stats, IAT, Byte counts
  → *Biến đổi được mà không mất DDoS behavior*

Ví dụ phân loại features

Loại	Feature
Functional	SYN Flag Count
Functional	Protocol
Functional	Fwd Header Length
Functional	Flow Duration
Non-functional	Flow Bytes/s
Non-functional	Packet Length Mean
Non-functional	Flow IAT Std

Kiến trúc: WGAN-GP + MLP Detector

Generator (G)

- Input: $z \sim \mathcal{N}(0, I_{64})$
- Layers: $64 \to 128 \to 256 \to 256 \to 128 \to 80$
- Output: Fake DDoS sample (80 features)

Critic (C) – Wasserstein

- Layers: $80 \to 256 \to 128 \to 64 \to 1$
- Loss: Wasserstein + Gradient Penalty (λ_{GP}=10)

MLP Detector

- Layers: $80 \to 256 \to 128 \to 64 \to 1$
- Activation: ReLU + Sigmoid, Dropout 0.3

Loss Function Generator

Phase A: $\mathcal{L}_G = -\mathbb{E}[C(G(z))] + \lambda_c \mathcal{L}_{con}$

Phase B:

$$\mathcal{L}_G = -\mathbb{E}[C(G(z))] + \lambda_{adv}\,\mathrm{BCE} + \lambda_c\,\mathrm{MSE}(G(z)[F], \mu_F)$$

F: functional features, μ_F: mean real DDoS
λ_{adv}=1.0, λ_c=5.0

Pipeline tổng thể

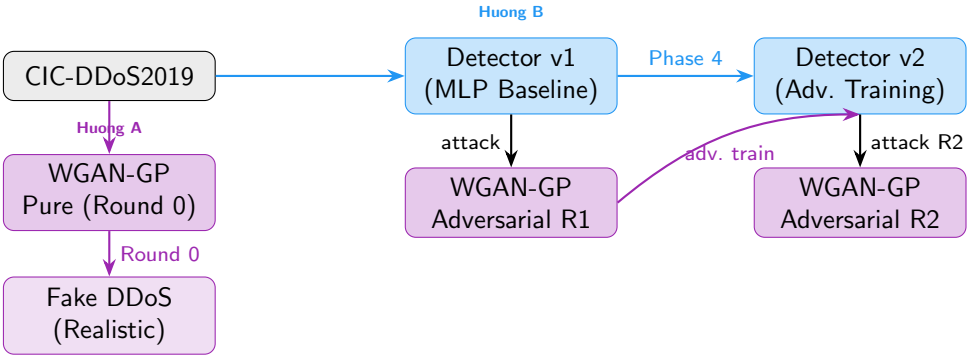

Hướng A: Validity Score – Metric mới đề xuất

Định nghĩa Validity Score

% fake samples có **tất cả** functional features trong valid range của real DDoS:

$$V = \frac{1}{N} \sum_{i=1}^{N} \prod_{f \in F} \mathbf{1}[x_i^f \in [lo_f, hi_f]]$$

Valid range: $[P_1, P_{99}]$ của real DDoS traffic

Kết quả tổng thể

Overall Validity = 0%

(AND condition: 11 features có valid range cực hẹp sau normalization)

Per-feature Validity ($\lambda_c = 5.0$, Round 0)

Feature	Validity
Flow Duration	100.0%
ACK Flag Count	99.9%
Fwd URG Flags	99.9%
Bwd PSH Flags	99.9%
URG Flag Count	99.7%
Protocol	0.0%
SYN Flag Count	0.0%
Fwd Header Length	0.0%
... (8 others)	0.0%

Hướng B: AUC cao – Ý nghĩa vs F1=0

Hiện tượng thú vị

Round 2: **F1 = 0.0000** nhưng **AUC = 0.9888**

Giải thích

- AUC đo *ranking*: detector vẫn gán xác suất DDoS cao hơn cho real DDoS so với fake
- Nhưng **tất cả fake samples** có $P < 0.5$ $\rightarrow$ phân loại là BENIGN
- GAN không cần tạo fake "giống real", chỉ cần **đẩy samples vào vùng BENIGN** của feature space

Evasion Strategy

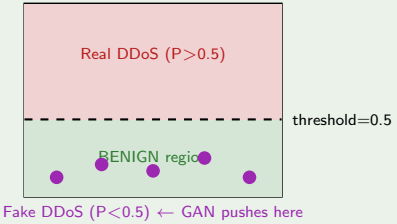

Hướng A: Validity Heatmap – Per-feature × Round

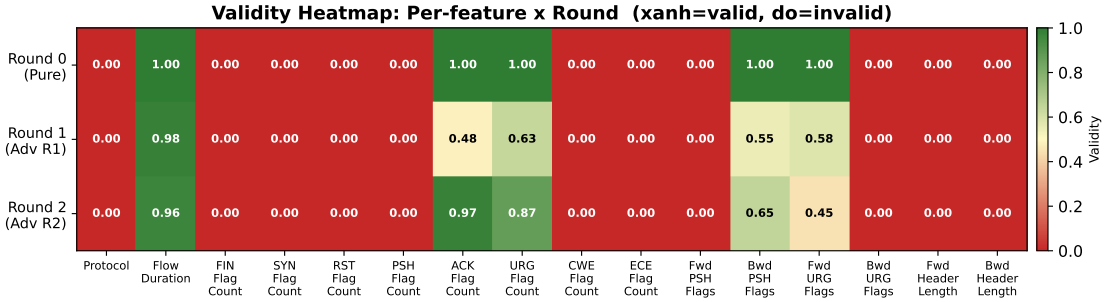

Tại sao 11 features = 0%?

Valid range sau normalization cực hẹp (min ≈ max) – GAN continuous float không thể rơi vào.
Không phải lỗi GAN mà là đặc tính data.

Key finding + Hướng cải thiện

Round 0 giống real nhất (KL=1.49 vs 1.61 Adv).
Fix: Post-processing snap về mode + Conditional GAN.

Hướng A: Phân phối các features — Real vs Fake DDoS

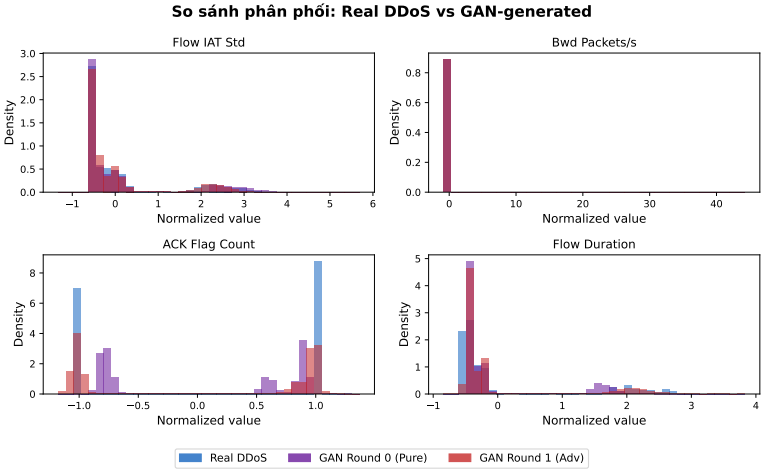

Pure GAN (tím) tiệm cận Real DDoS (xanh) hơn Adversarial GAN (đỏ)

Hướng A: Per-feature Validity — So sánh 3 round

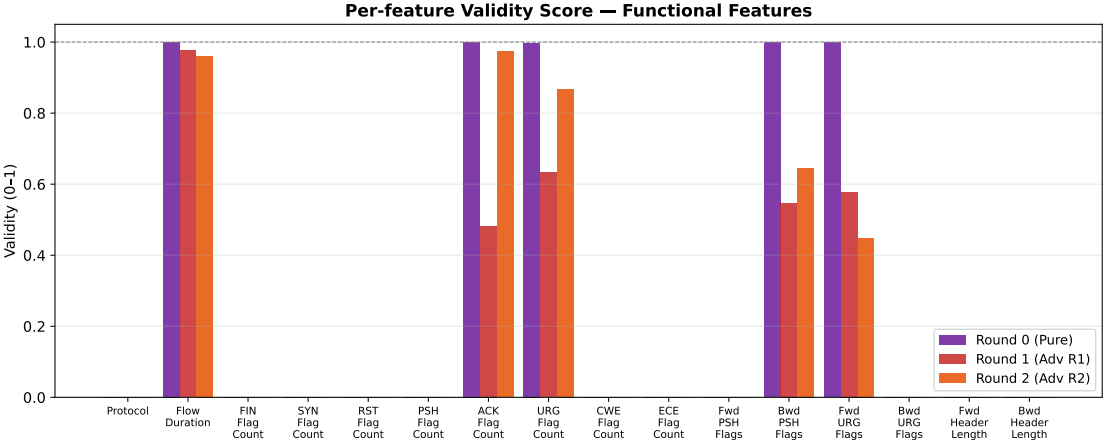

5 features đạt ≈ 100% validity (Round 0); Adversarial rounds giảm validity do conflict với bypass objective

Hướng B: Kết quả Arms Race – Bảng tổng hợp

Phase	Detector	F1	AUC	FNR	FoolRate
Phase 1 – Baseline	MLP v1	**0.9996**	1.0000	0.0003	–
Phase 3 – GAN Round 1	MLP v1	**0.0000**	0.9942	1.0000	**1.0000**
Phase 4 – MLP v2 (real)	MLP v2	**0.9996**	1.0000	0.0003	–
Phase 4 – MLP v2 (adv set)	MLP v2	**0.9998**	1.0000	0.0000	–
Phase 5 – GAN Round 2	MLP v2	**0.0000**	0.9888	1.0000	**1.0000**
Transferability – RF (R1)	RF	0.5325	0.9998	0.6371	0.6371

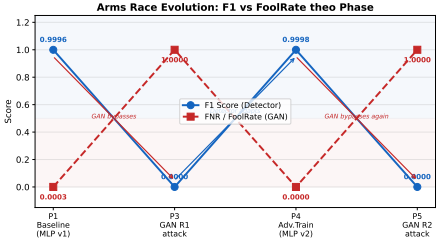

Hướng B: FoolRate qua các Round

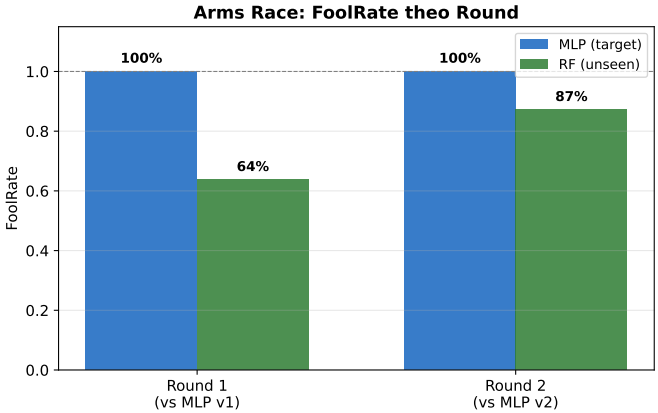

Nhận xét

- MLP FoolRate = **100%** cả 2 rounds
- RF FoolRate tăng 63.7% → 87.2% Transferability cải thiện
- GAN học patterns tổng quát hơn theo round

Hướng B: Transferability – GAN bypass cross-architecture

Thí nghiệm Transferability

GAN được train **chỉ** trên MLP Detector, sau đó test trên **Random Forest** – kiến trúc hoàn toàn khác

	FoolRate	
Detector	**Round 1**	**Round 2**
MLP v1 (target R1)	1.0000	0.0008
MLP v2 (target R2)	–	1.0000
RF (unseen)	**0.6371**	**0.8716**

Findings

- RF FoolRate **tăng** từ 63.7% → 87.2% (Round 1 → 2)
- GAN round 2 học được features tổng quát hơn khi phải bypass detector mạnh hơn
- **Rủi ro thực tế:** Adversarial samples có thể bypass nhiều loại IDS, không chỉ target
- GAN Round 2 chuyên biệt hóa: MLP v1 FoolRate giảm xuống 0.08%

Hướng B: KL Divergence — Chất lượng phân phối

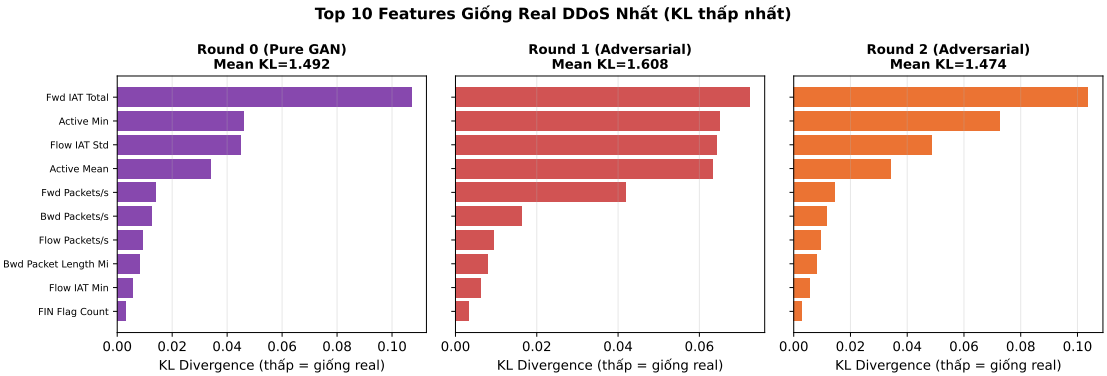

Top 10 features giống real nhất (KL thấp nhất). Round 0 có Mean KL thấp hơn — fake gần real DDoS hơn.

SHAP: Giải thích thay đổi của Detector

Mục tiêu SHAP

So sánh feature importance của Detector v1 vs v2 sau adversarial training:
Liệu v2 có chú trọng hơn vào functional features?

Group	v1	v2	Δ
Functional	0.4794	0.4458	−0.034
Non-functional	0.4660	0.3998	−0.066

Finding

- **Không có shift** từ non-functional sang functional features
- Cả hai group **giảm** sau adv. training – model trở nên *less confident* tổng thể
- GAN bypass qua **non-functional features** (consistent với Validity=0)

Implication

Để detector mạnh hơn, cần penalize GAN khi modify **functional features** – đây là lý do cần constraint loss $\mathcal{L}_{con}$

SHAP: Biểu đồ Feature Importance

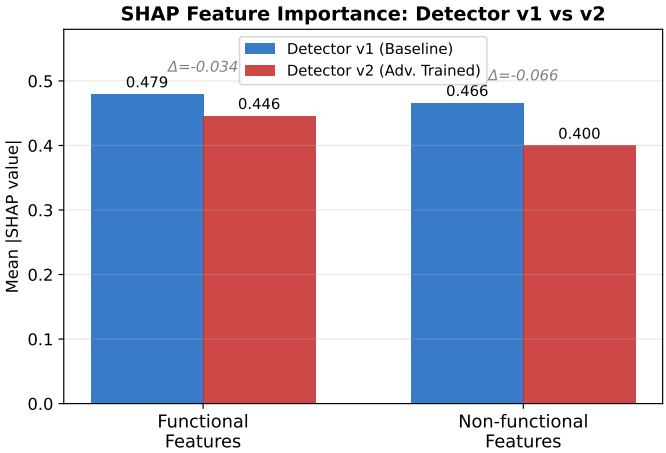

Finding

- Cả hai group **giảm** sau adv. training
- Không có shift non-func → functional
- Model *less confident* tổng thể

Tóm tắt kết quả

Đã đạt được

- ✓ **Hướng A**: 5/16 functional features validity > 99% với $\lambda_c = 5.0$
- ✓ **Hướng B**: GAN bypass hoàn toàn cả Detector v1 & v2 (F1 = 0.0)
- ✓ **Adv. Training**: Detector v2 phục hồi (F1=0.9998 trên adversarial set)
- ✓ **Transferability**: RF FoolRate 63.7% → 87.2%
- ✓ **SHAP**: Phân tích attention shift
- ✓ **Validity Score**: Metric mới đề xuất

Hạn chế & Hướng phát triển

- ✗ Overall Validity = 0 do AND condition → Cần post-processing hoặc Conditional GAN
- ✗ SHAP không thấy attention shift → Cần thêm epochs / stronger adv. training
- ✗ Chỉ 1 dataset (CIC-DDoS2019) → Thêm UNSW-NB15, CICIDS2017
- ✗ Chưa so sánh với FGSM, PGD → Cần baseline comparison cho paper

Kết luận

Pipeline hoàn chỉnh đã triển khai

Data $\rightarrow$ **Detector v1** $\xrightarrow{\text{bypass}}$ **GAN Round 1** $\xrightarrow{\text{adv. train}}$ **Detector v2** $\xrightarrow{\text{bypass}}$ **GAN Round 2**

- **Đề tài hoàn thành:** Pipeline sinh mẫu DDoS bằng GAN kết hợp arms race với detector
- **Finding chính:** GAN bypass hoàn toàn MLP detector (F1: 0.9996 $\rightarrow$ 0.0000); Transferability cross-architecture đạt **87.2%**
- **Validity Score:** Metric mới – chưa có paper nào áp dụng trên CIC-DDoS2019
- **Hướng tiếp theo:** Conditional GAN + constraint mạnh hơn để tăng Validity > 0 toàn bộ

THANK YOU!