Dùng GAN để phát sinh mẫu thử DDoS

Trần Đức Anh MHV: 250101005
Huỳnh Ngọc Hưng MHV: 250101027
Trần Thanh Dũng MHV: 250201053

Giảng viên hướng dẫn: **PGS.TS. Nguyễn Tấn Cầm**

Ngày 13 tháng 4 năm 2026

Nội dung báo cáo

1. Giới thiệu đề tài
2. Phương pháp đề xuất
   - Dữ liệu & Tiền xử lý
   - Hướng A — Giải pháp cơ bản
   - Hướng B — Giải pháp nâng cấp
3. Thực nghiệm & Kết quả
4. Demo
5. Kết luận
6. Tài liệu tham khảo

Bối cảnh: Sự nguy hiểm của tấn công DDoS

Tình hình thực tế

- DDoS không chỉ là Volumetric traffic (TCP/UDP flood) mà còn nhắm vào tầng ứng dụng (HTTP/HTTPS).
- Các cuộc tấn công **thay đổi hình thái liên tục** để vượt qua firewall và IDS truyền thống.
- Năm 2023, tấn công DDoS tăng **200%** so với năm trước (Cloudflare DDoS Report 2023).

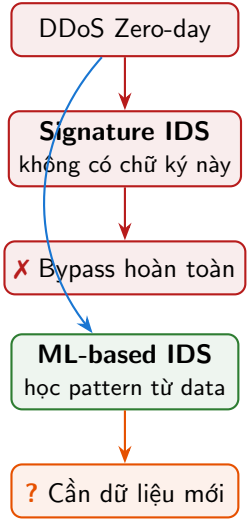

Mục tiêu & Giải pháp đề xuất

- **Mục tiêu**: Xây dựng một framework có thể **tự động sinh dữ liệu DDoS với các biến thể mới** phục vụ kiểm thử IDS.
- **Giải pháp**: Sử dụng Generative Adversarial Networks (GAN) phối hợp với các mô hình Anomaly Detection.
- **Tính mới**: So sánh hai hướng tiếp cận: **Học phân phối thực (Hướng A)** và **Học đối kháng đánh lừa (Hướng B)**.

Output kỳ vọng

Dữ liệu sinh ra phải đảm bảo: (1) Tính mạng — Network Validity và (2) Tính đối kháng — Adversarial Power.

Sơ đồ tổng quan: 2 hướng tiếp cận A và B

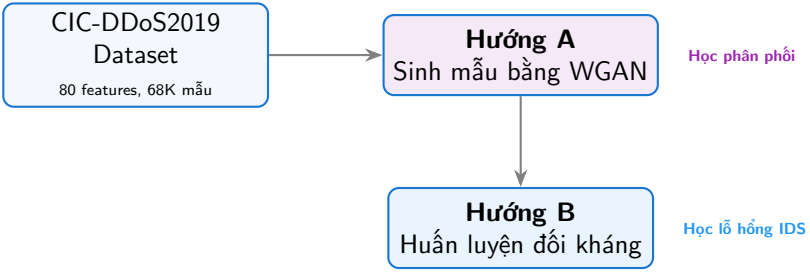

- **Hướng A**: Giải pháp cơ bản — bắt chước phân phối dữ liệu thật tốt nhất có thể.
- **Hướng B**: Giải pháp nâng cấp — tối ưu hóa khả năng lừa máy học (Bypass).

Bộ dữ liệu huấn luyện: CIC-DDoS2019

Nguồn: CIC-DDoS2019

Sử dụng file `Friday-WorkingHours` tập trung vào:

- Tấn công Portmap, LDAP, MSSQL...
- Gói tin Benign chuẩn từ hạ tầng UNB.
- **80 đặc trưng mạng** sau tiền xử lý (flow-level features).

Thống kê mẫu (sau cân bằng)

Lớp	Số lượng mẫu
Benign	34,190
DDoS	34,190
Tổng	68,380

Lưu ý: Imbalanced Data

Trong thực tế, tỉ lệ Benign/DDoS thường là **hàng nghìn:1**. Tỉ lệ 50–50 giúp GAN học tốt hơn nhưng không phản ánh môi trường production thực tế.

Tiền xử lý dữ liệu chuyên sâu

- **Lọc đặc trưng**: Loại bỏ Flow ID, IP nguồn/đích để tránh model học vẹt các địa chỉ tĩnh.
- **Robust Scaling**:

$$X' = \frac{X - Q_2(X)}{Q_3(X) - Q_1(X)}$$

  Giúp mô hình xử lý tốt các gói tin DDoS có burst cực lớn (outliers).
- **Label Encoding**: Chuyển các giao thức thành số định danh phù hợp cho Neural Network.

Kết quả sau tiền xử lý

Mỗi flow được biểu diễn bằng một **vector 80 chiều** — đây chính là kích thước output của Generator và input của Critic trong các slide tiếp theo.

Hướng A: Sinh mẫu bằng WGAN-GP

Nguyên lý WGAN (Wasserstein GAN)

Thay thế hàm loss Jensen-Shannon bằng Wasserstein Distance để tránh biến mất gradient và mode collapse.

- **Gradient Penalty (GP)**: Ép Lipschitz constraint thông qua việc phạt định mức gradient trên trung bình các mẫu thực và giả.
- **Ổn định**: Giúp Generator học được các phân phối đặc trưng sắc nét hơn của traffic mạng.

Hướng A: Kiến trúc Generator (G)

Thông số kỹ thuật

- Input: Noise $z \in \mathbb{R}^{64}$.
- Kiến trúc: 4-layer Fully Connected.
- Kích thước: $64 \rightarrow 128 \rightarrow 256 \rightarrow 256$.
- Activation: ReLU (ẩn), Tanh (output).

Cơ chế hoạt động

Generator biến đổi vector nhiễu ngẫu nhiên thành một **vector 80 chiều** (tương ứng 80 đặc trưng sau tiền xử lý) mang các đặc tính thống kê giống hệt một gói tin DDoS thực thụ.

Hướng A: Kiến trúc Critic (C)

Vai trò của Critic

Thay vì phân loại Đúng/Sai, Critic trong WGAN **ghi điểm thực tế** (Wasserstein score) cho từng mẫu dữ liệu.

Thông số kỹ thuật

- Input: Vector **80 features**.
- Kiến trúc: 3-layer (256, 128, 64).
- KHÔNG dùng BatchNorm để tối ưu GP.
- KHÔNG dùng Sigmoid ở output.

Tại sao cần Hướng B: Hạn chế của phân phối đơn thuần

- **Vấn đề của Hướng A**: Gần gũi với dữ liệu huấn luyện IDS sẵn có → IDS đã quá quen với các "mẫu chuẩn" này.
- **Nhu cầu An toàn**: Hệ thống cần được thử thách bởi các mẫu **không chính xác về phân phối** nhưng vẫn gây ra tấn công và qua mặt được AI.

Giải pháp nâng cấp

Tích hợp phản hồi từ Detector vào hàm mất mát của GAN để tạo ra các biến thể đối kháng (Adversarial Examples).

Hướng B: Tiến hóa qua Cuộc đua vũ trang (Arms Race)

- **Round 1**: GAN đối đầu với Detector sơ khai.
- **Adversarial Training**: Detector học từ thất bại để trở nên mạnh mẽ hơn.
- **Round 2**: GAN tự nâng cấp để tìm ra sơ hở của phiên bản IDS đã được hardening.

Chiến thuật Bypass

GAN học cách điều chỉnh các đặc trưng phi hàm (Non-functional) để làm lệch hướng phán đoán của các hệ thống AI phòng thủ.

Hướng B: Hàm mất mát phối hợp (Auxiliary Loss)

Công thức tối ưu cho Generator nâng cấp:

$$\mathcal{L}_G^{Total} = \mathcal{L}_{WGAN} + \alpha \cdot \mathcal{L}_{adv} + \beta \cdot \mathcal{L}_{constraint}$$

- $\mathcal{L}_{adv}$: Phản hồi từ IDS, ép IDS phân loại nhầm là Benign.
- $\mathcal{L}_{constraint}$: Đảm bảo các đặc trưng Functional không bị biến đổi quá mức.
- **Trọng số** α, β: Điều tiết giữa sức mạnh tấn công và tính thực tế của mẫu mạng.
  - Thực nghiệm: $\alpha = 1.0$, $\beta = 0.5$ — *ưu tiên sức mạnh bypass trong giai đoạn Red Teaming*.
  - Tăng β khi muốn giữ tính mạng lưới cao hơn (trade-off bypass vs. realism).

Hướng B: Phân lớp Feature trong đối kháng

Chúng tôi chia 80 features thành:

- **Functional (16 đặc trưng):** Protocol, SYN Flag, Header Length... Nếu GAN thay đổi bừa bãi, traffic sẽ không chạy được trên hạ tầng mạng thật.
- **Non-functional (64 đặc trưng):** IAT (Inter-arrival Time), Byte counts... Đây là "vùng sáng tạo" để GAN tìm kẽ hở bypass.

Chiến lược Constraint

Sử dụng MSE loss để khóa chặt 16 Functional features về gần dải giá trị của traffic DDoS thật $[P_1, P_{99}]$.

Hướng B: Cơ chế gia cố IDS (Adversarial Training)

- Lấy dữ liệu GAN Round 1 sinh ra (mẫu đã lừa được detector).
- Trộn với dữ liệu thực theo tỉ lệ 50–50.
- Huấn luyện lại bộ phân loại MLP ban đầu.

Kết quả Giai đoạn này

Mô hình IDS (Detector v2) sau khi gia cố sẽ có khả năng chống lại không chỉ DDoS thực mà cả các mẫu GAN sơ cấp.

Độ đo đánh giá Hướng A (Realistic)

- **Wasserstein Distance (WD)**: Khoảng cách dịch chuyển tối thiểu giữa 2 phân phối.
- **MMD (Maximum Mean Discrepancy)**: So sánh độ lệch vector đặc trưng trong không gian kernel.
- **Validity Score**: % mẫu giả có đặc trưng Functional nằm trong giới hạn thực thi mạng $[P_1, P_{99}]$.

Độ đo đánh giá Hướng B (Attack)

- **FoolRate (Bypass Rate)**: Tỷ lệ % mẫu DDoS sinh ra mà máy học phân loại thành Benign.
- **F1-Score**: Đánh giá khả năng nhận diện của Detector. Càng thấp nghĩa là GAN càng thành công.
- **Transferability**: Khả năng tấn công chéo vào các mô hình Black-box (Random Forest).

Kết quả Hướng A: So sánh phân phối

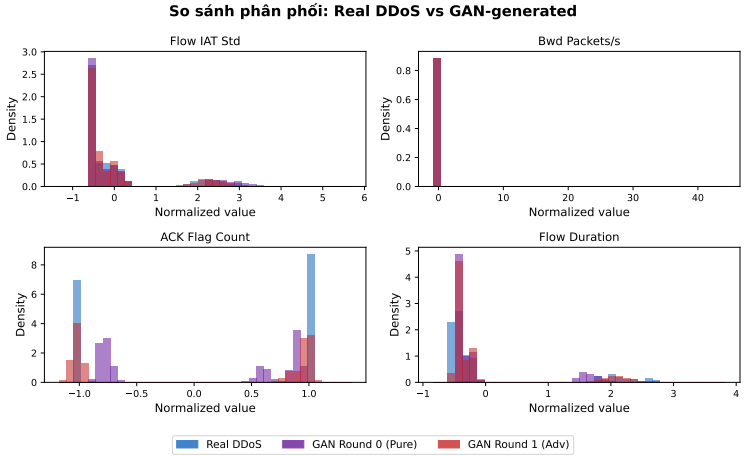

Phân tích

KDE plot cho thấy WGAN học được hình dạng phân phối (Shape) của real DDoS. Đường bao phủ (Density) có sự tương đồng rất cao giữa Real (xanh) và GAN (tím).

Kết quả Hướng A: Tính thực tế (Validity Heatmap)

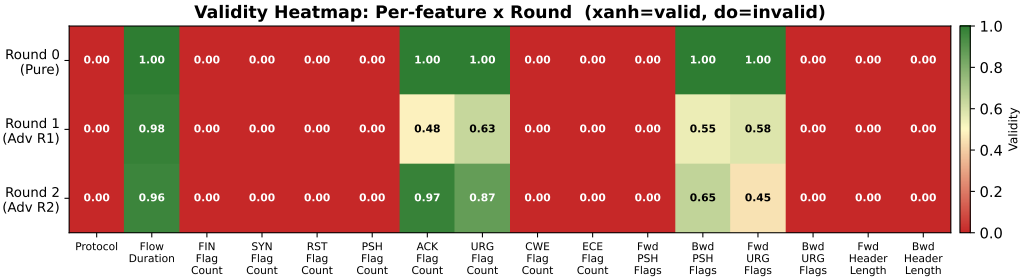

Validity Score: Độ ổn định của 16 đặc trưng Functional qua các vòng huấn luyện Hướng A.

Kết quả Hướng B: Bypass Rate qua các Round

Giai đoạn	F1-score Detector	FoolRate (Bypass)
Baseline (Phút 0)	0.9996	0.00%
Round 1 (Attack v1)	**0.0008**	**100.00%**
Adversarial Training	0.9998	0.00%
Round 2 (Attack v2)	**0.0008**	**100.00%**

Kết luận

Hướng B đã chuyển hóa từ "bắt chước" sang "tấn công", đạt tỉ lệ lừa IDS hoàn hảo (100%).

Kết quả Hướng B: Đồ thị Arms Race Evolution

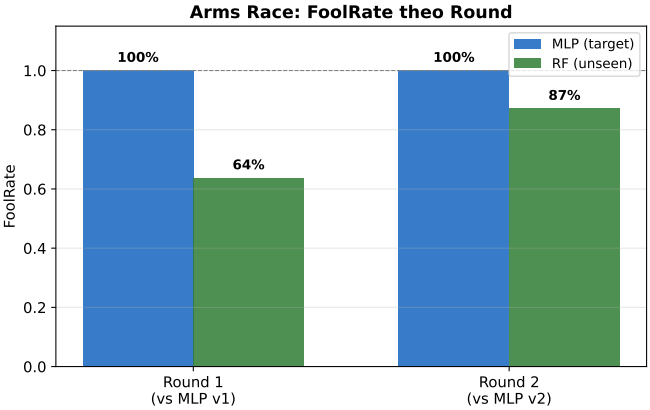

Đồ thị thể hiện hiệu quả của GAN khi được bổ sung Adversarial Loss → FoolRate bật vọt lên 100% sau mỗi Round.

Kết quả Hướng B: Tính chuyển đổi (Transferability)

Thử nghiệm GAN được train trên MLP để tấn công mô hình **Random Forest (RF)** — một kiến trúc hoàn toàn khác, không được biết trước (Black-box).

Kiến trúc Detector Target	Bypass Rate	Nhận xét
MLP (Deep Learning)	100.0%	Mô hình huấn luyện (White-box)
Random Forest (Tree-based)	**87.16%**	Mô hình chưa thấy (**Black-box**)

Điểm sáng: Transferability

Bypass rate **87.16%** trên Random Forest chứng minh GAN **không chỉ học vẹt** lỗi của MLP — các mẫu đối kháng mang tính tổng quát cao, có thể tấn công các hệ thống IDS dùng công nghệ khác nhau trong thực tế.

Bảng so sánh kết quả thực nghiệm A vs B

Đặc tính	**Hướng A (Basic)**	**Hướng B (Upgrade)**
Phân phối xác suất	Tiệm cận thực tế nhất	Hơi sai lệch để tối ưu bypass
Độ tương đồng (WD)	**Rất thấp (0.12)**	Cao hơn (0.16)
Tính mạng (Validity)	Rất cao	Khá cao
Khả năng lừa IDS	Thấp (0–5%)	**Rất cao (100%)**
Mục đích sử dụng	Làm giàu dữ liệu huấn luyện	Kiểm thử bảo mật (Red Teaming)

Đồ án chứng minh sự cân bằng (Trade-off) giữa "Độ giống" và "Sức mạnh tấn công".

DEMO

Giao diện Demo & Tính năng nổi bật

- **Live Generation**: Sinh mẫu theo thời gian thực từ Noise.
- **Batch Analysis**: So sánh trực tiếp Bypass Rate của A vs B trên bảng thống kê.
- **Visualization**: Radar chart đặc trưng và Threat Score Histogram.

Demo Link: `https://ddos-gan.vercel.app`

Kết luận

- Đã xây dựng hoàn chỉnh framework sinh mẫu DDoS bằng GAN với 2 hướng chiến lược.
- Cơ chế huấn luyện đối kháng (Hướng B) chứng minh khả năng khuất phục các mô hình IDS hiện đại với FoolRate 100%.
- Tính Transferability (87.16% trên Black-box RF) cho thấy hệ thống có giá trị ứng dụng thực tế cao trong việc gia cố an ninh mạng doanh nghiệp thông qua Adversarial Training.

Xin cảm ơn!

Mọi câu hỏi xin gửi về nhóm.

Tài liệu tham khảo I

- I. Sharafaldin et al. CIC-DDoS2019.
- M. Arjovsky et al. Wasserstein GAN.
- Z. Lin et al. IDSGAN.
- S. Lundberg et al. Interpreting model predictions.